

B2B 데이터 분석 도메인 커스텀 플랫폼

서비스 개요

기업의 DB, 쿼리 로그, BI 문서, 현장 용어를 자동 분석해 고객사 전용 데이터 분석 플랫폼을 구축하고, 자연어 질의·SQL 생성·시각화·부서별 가드레일을 제공하는 엔드투엔드 플랫폼.

핵심 포지셔닝

이 서비스는 단순 Text-to-SQL 도구가 아니라, 기업의 데이터베이스를 스캔하고, 컬럼·값·지표·현장 용어를 자동 문서화한 뒤, 사람 검수를 통해 기업별 시맨틱 레이어와 분석 에이전트를 구축하는 커스텀 데이터 분석 플랫폼

1. 문제 정의 / 타겟 사용자 / 핵심 기능 / 경쟁 서비스 비교

1-1. 문제 정의

기업은 자연어 기반 데이터 분석을 도입하고 싶어 하지만, 실제 문제는 “SQL 생성” 자체가 아니다.

상용 LLM이나 오픈소스 모델은 SQL 문법을 어느 정도 생성할 수 있지만, 기업 내부의 데이터 맥락을 모른다.

예를 들어 현업 사용자가 다음과 같이 질문한다고 하자.

“지난달 신규 고객 매출이 캠페인별로 어땠어?”

이 질문을 정확히 처리하려면 LLM은 다음을 알아야 한다.

필요한 지식	예시

신규 고객의 현장 정의	가입일 기준인지, 첫 결제일 기준인지, 첫 주문일 기준인지
매출의 현장 정의	주문금액인지, 결제금액인지, 환불 제외 순매출인지
캠페인 매핑 방식	UTM 기준인지, 내부 campaign_id 기준인지
기간 기준	주문일, 결제일, 정산일 중 무엇인지
부서별 권한	마케팅팀이 재무 테이블을 볼 수 있는지
컬럼 값의 의미	<code>status = 'A', status = 'C', type = 'B2B'</code> 가 실제로 무엇을 뜻하는지

기존 Text-to-SQL 도구는 주로 DB의 물리적 스키마를 기반으로 SQL을 생성한다. 그러나 실제 기업 데이터 분석에는 물리적 스키마보다 비즈니스 용어, 현장 관습, 컬럼 값의 의미, 지표 계산 방식, 부서별 접근 정책이 더 중요하다.

Snowflake Cortex Analyst도 Text-to-SQL 정확도를 높이기 위해 semantic model, semantic view, verified query를 사용한다. 이는 단순 스키마만으로는 기업 분석 질의를 안정적으로 처리하기 어렵다는 점을 보여준다.

BigQuery Conversational Analytics 역시 custom metadata, glossary, verified query 등을 통해 데이터 에이전트가 조직의 비즈니스 로직을 학습하도록 구성한다.

Databricks Genie도 domain expert가 datasets, sample queries, text guidelines를 설정해 조직 용어와 데이터에 맞는 분석 공간을 구성하도록 한다.

따라서 이 서비스가 풀 문제는 다음과 같다.

기업마다 다른 데이터 구조와 현장 용어를 자동으로 수집·문서화·검증해, 별도 모델 파인튜닝 없이도 해당 기업의 업무 맥락을 이해하는 데이터 분석 플랫폼을 빠르게 구축하는 것.

핵심 문제 상황

1. DB 스키마만으로는 도메인 맥락을 알 수 없음

컬럼명이 `status`, `type`, `code`, `category`, `channel`, `segment`처럼 추상적인 경우, LLM은 실제 의미를 알 수 없다.

예시:

`users.status` 값이 다음과 같다고 하자.

값	실제 의미
A	활성 고객
D	탈퇴 고객
S	휴면 고객
B	차단 고객

이 정보가 문서화되어 있지 않으면, LLM은 `A`, `D`, `S`, `B`의 의미를 추측할 수밖에 없다.

2. 현장 용어는 **DB** 컬럼명과 다르다

현업은 “활성 고객”, “신규 고객”, “순매출”, “이탈 고객”, “전환 고객”이라고 말하지만, **DB**에는 다음처럼 저장되어 있을 수 있다.

현장 용어	실제 구현
활성 고객	<code>users.deleted_at IS NULL AND users.status = 'A'</code>
신규 고객	<code>first_paid_at</code> 이 해당 기간에 속한 고객
순매출	<code>payment.amount - refund.amount - coupon_discount</code>

전환 고객	<code>event_name = 'purchase_completed'</code> 발생 사용자
이탈 고객	최근 90일간 주문 없음

따라서 기업용 분석 플랫폼은 현장 용어와 **DB** 구현 사이의 매핑을 자동으로 만들어야 한다.

3. 기존 방식은 사람이 프롬프트에 도메인 지식을 계속 하드코딩해야 함

많은 **Text-to-SQL PoC**는 다음 방식으로 진행된다.

1. **DB** 스키마를 프롬프트에 넣음
2. 중요한 테이블 설명을 사람이 작성함
3. 지표 정의를 프롬프트에 추가함
4. 예시 **SQL**을 **few-shot**으로 넣음
5. 틀리면 다시 프롬프트를 수정함

문제는 이 방식이 운영 환경에서 유지되지 않는다는 점이다.

- 테이블이 계속 추가됨
- 컬럼명이 변경됨
- 지표 정의가 부서마다 다름
- 현장 용어가 계속 바뀜
- 신규 직원은 기존 정의를 모름
- 데이터팀이 모든 프롬프트를 관리할 수 없음

4. 전통적인 모델 학습 없이도 기업 도메인 지식을 반영해야 함

기업 입장에서는 매번 모델을 파인튜닝하기 어렵다.

- 학습 데이터셋 구축 비용이 큼
- 보안 이슈가 있음
- 고객사별 모델을 따로 관리하기 어려움
- 데이터 구조가 바뀌면 다시 학습해야 함
- 작은 **PoC**에는 과도한 방식임

따라서 이 서비스의 접근은 다음과 같다.

모델 파라미터를 학습시키는 것이 아니라, **DB** 스캐닝·값 사전·현장 용어·지표 정의·검증 **SQL**을 자동 문서화하고 **VDB**에 임베딩하여, 질의 시점에 필요한 도메인 맥락을 검색해 **LLM**에 주입한다.

즉, **Fine-tuning** 기반이 아니라 설계로 풀어야한다고 생각했습니다.

[Context Engineering / RAG / Semantic Layer 기반]

1-2. 타겟 사용자

1차 타겟

기업 내부 데이터 분석 플랫폼을 구축하려는 **AI/데이터/플랫폼** 팀

사용자	니즈
AI 솔루션 엔지니어	고객사 DB를 빠르게 분석해 맞춤형 자연어 분석 플랫폼을 구축하고 싶음
데이터 플랫폼 엔지니어	여러 DB, 지표, 권한 정책을 통합 관리하고 싶음
데이터 분석가 / DA	현업 질문을 줄이고, 지표 정의를 표준화하고 싶음
AI 에이전트 개발자	Text-to-SQL 에이전트에 기업별 도메인 컨텍스트를 주입하고 싶음
B2B SaaS 개발팀	자사 고객사별로 커스텀 분석 에이전트를 제공하고 싶음

2차 타겟

기업 내부 현업 사용자

사용자	사용 목적
마케팅팀	캠페인 성과, 전환율, 유입 채널 분석
세일즈팀	고객 세그먼트, 리드, 계약 전환 분석
CX팀	문의 유형, 처리 시간, 고객 불만 분석
재무팀	매출, 환불, 정산, 비용 분석
PM/PO	기능 사용량, 퍼널, 리텐션 분석
경영진	핵심 KPI 요약, 이상 징후 확인

1-3. 핵심 기능

A. LLM 기반 DB 스캐닝 / 프로파일링

초기 세팅 단계에서 고객사 DB에 read-only로 연결한 뒤, LLM과 metadata query를 활용해 DB 구조를 분석한다.

수집 대상:

구분	수집 항목
스키마 정보	DB, schema, table, column, data type, nullable

관계 정보	PK/FK 후보, join key 후보, 자주 등장하는 ID 컬럼
값 정보	distinct value, top frequent value , null ratio, min/max
날짜 정보	기간 컬럼 후보, event time, created_at, paid_at
카테고리 정보	status, type, channel, category, segment 등
민감정보 후보	email, phone, address, name, card, resident_id
분석 후보	지표화 가능한 fact table, dimension table, event table
쿼리 패턴	기존 쿼리 로그, BI 대시보드 SQL, 자주 쓰는 조인

중요한 점은 모든 값을 무작정 수집하지 않는 것이다.

저카디널리티 컬럼:

- DISTINCT / top N 값 수집
- category dictionary로 문서화

고카디널리티 컬럼:

- raw value 전체 수집 금지
- sample, pattern, distribution만 수집

PII 의심 컬럼:

- 값 수집 금지
- 컬럼명과 마스킹 정책만 문서화

B. 컬럼별 값 사전 자동 구축

DISTINCT, COUNT, APPROX_COUNT_DISTINCT, TOP N 등을 활용해 컬럼별로 “카테고라이징 가능한 값”을 수집한다.

예시:

```
SELECT status, COUNT(*) AS cnt
FROM users
GROUP BY status
ORDER BY cnt DESC
LIMIT 50;
```

이 결과를 기반으로 다음과 같은 값 사전을 만든다.

```
{
  "table": "users",
  "column": "status",
  "data_type": "string",
  "cardinality": 4,
  "distinct_values": [
    {
      "value": "A",
      "count": 120340,
      "llm_guess": "활성 고객",
      "human_confirmed_label": "활성 고객"
    },
    {
      "value": "D",
      "count": 18320,
      "llm_guess": "탈퇴 고객",
      "human_confirmed_label": "탈퇴 고객"
    },
    {
      "value": "S",
      "count": 9230,
      "llm_guess": "휴면 고객",
      "human_confirmed_label": "휴면 고객"
    }
  ],
  "business_terms": ["회원 상태", "고객 상태"],
  "usage_notes": "고객 활성/휴면/탈퇴 분석 시 필수 필터로 사용"
}
```

이 문서는 VDB에 임베딩되어, 이후 사용자가 “활성 고객만 봐줘”라고 질문하면 LLM이 `users.status = 'A'`를 검색해 사용할 수 있다.

C. 현장 용어 확인 질문 리스트 자동 생성

DB를 스캔한 뒤, 시스템은 바로 분석 에이전트를 만들지 않는다.
먼저 LLM이 확인해야 할 현장 용어 질문 리스트를 생성한다.

이 기능이 이 서비스의 핵심 차별점이다.

예시: 자동 생성 질문 리스트

1. 고객 관련 질문

질문	확인 대상
“신규 고객”은 가입일 기준인가요, 첫 주문일 기준인가요, 첫 결제일 기준인가요?	신규 고객 정의
“활성 고객”은 <code>status = 'A'</code> 기준인가요, 최근 로그인/구매 이력 기준인가요?	활성 고객 정의
“이탈 고객”은 몇 일 이상 구매가 없는 고객인가요?	이탈 기준
휴면 고객과 탈퇴 고객은 현업에서 어떻게 구분하나요?	상태값 해석

2. 매출 관련 질문

질문	확인 대상
“매출”은 주문금액, 결제금액, 정산금액 중 무엇인가요?	매출 기준
환불 금액은 매출에서 제외하나요?	순매출 정의
쿠폰 할인, 포인트 사용액, VAT는 매출 계산에서 어떻게 처리하나요?	계산식
월별 매출은 주문일, 결제일, 정산일 중 어떤 날짜를 기준으로 하나요?	기간 기준

3. 마케팅 관련 질문

질문	확인 대상
캠페인 성과는 UTM 기준인가요, 내부 campaign_id 기준인가요?	캠페인 attribution
전환은 회원가입, 장바구니, 결제 완료 중 무엇을 의미하나요?	전환 정의
ROAS 계산 시 광고비 테이블은 어떤 테이블을 기준으로 하나요?	비용 매핑
organic, direct, referral 값은 현업에서 어떻게 분류하나요?	채널 사전

4. 테이블/컬럼 의미 질문

질문	확인 대상
----	-------

<code>orders.status = 'COMPLETE'</code> 는 결제 완료인가요, 배송 완료인가요?	주문 상태
<code>payments.type = 'NORMAL'</code> 과 <code>payments.type = 'BILLING'</code> 의 차이는 무엇인가요?	결제 유형
<code>users.grade = 'VIP'</code> 는 어떤 기준으로 부여되나요?	등급 정의
<code>events.event_name = 'purchase'</code> 와 <code>orders</code> 테이블의 구매 데이터 중 어떤 것을 공식 구매 기준으로 사용하나요?	fact source 선택

D. Human-in-the-loop 도메인 검수 UI

자동 생성된 추론 결과는 그대로 사용하지 않고, 현업 담당자 또는 데이터 담당자가 승인한다.

관리자 화면 예시:

항목	LLM 추론	담당자 확인	상태
신규 고객	첫 결제일 기준	첫 결제일 기준	승인
활성 고객	<code>status = 'A'</code>	<code>status = 'A' AND deleted_at IS NULL</code>	수정 후 승인
매출	<code>payments.amount</code>	<code>payments.amount - refunds.amount</code>	수정 후 승인
캠페인	<code>campaign_id</code> 기준	UTM 기준 우선, 없으면 <code>campaign_id</code>	수정 필요

이 과정을 통해 시스템은 단순히 DB를 읽는 것이 아니라, 현장 업무 정의를 수집하는 질문 생성 도구가 된다.

E. VDB 기반 도메인 메모리 구축

검수된 결과는 다음 단위로 문서화되고 VDB에 임베딩된다.

문서 단위	설명
Table Card	테이블의 역할, 주요 사용처, 조인 관계
Column Card	컬럼 의미, 타입, 값 분포, 사용 주의사항
Value Dictionary Card	distinct 값과 현장 용어 매핑
Metric Card	매출, 전환율, 리텐션 등 지표 계산식
Business Term Card	신규 고객, 활성 고객 등 용어 정의
Join Pattern Card	자주 쓰는 조인 경로

Policy Card	부서별 접근 권한, 금지 컬럼
Verified Query Card	검증된 자연어 질문과 SQL 쌍
Dashboard Card	기존 BI 대시보드의 목적과 SQL 로직

예시: **VDB**에 들어가는 문서

[Business Term Card]

용어: 신규 고객

현업 정의: 최초 결제일이 분석 기간에 속한 고객

관련 테이블:

- users
- payments

사용 컬럼:

- users.user_id
- users.first_paid_at
- payments.user_id
- payments.paid_at

SQL 조건:

users.first_paid_at >= {start_date}
AND users.first_paid_at < {end_date}

주의사항:

- users.created_at은 가입일이므로 신규 고객 매출 분석에는 사용하지 않는다.
- 첫 주문일이 아니라 첫 결제일 기준이다.
- 환불 여부는 매출 지표 정의에서 별도로 처리한다.

승인자: Data Analyst 김OO


승인일: 2026-05-01

이 문서가 임베딩되면, 사용자가 “신규 고객 매출”이라고 물었을 때 모델은 단순히 **users.created_at**을 추측하지 않고, “신규 고객 = first_paid_at 기준”이라는 도메인 컨텍스트를 검색해 SQL을 생성한다.

F. 전통적 학습 없는 도메인 적응 구조

이 플랫폼은 고객사별 모델을 새로 학습시키는 방식이 아니다.

대신 다음 구조로 동작한다.



즉, 이 서비스의 핵심 장치는 다음과 같다.

모델을 학습시키지 않고, 기업별 데이터 해석 문서를 자동 생성·검수·검색 가능하게 만들어 LLM이 해당 기업의 도메인 맥락을 이해하도록 만드는 것.

G. 고객사 전용 분석 플랫폼 생성

최종 결과물은 단순 API가 아니라 고객사 전용 데이터 분석 플랫폼이다.

구성 요소:

구성 요소	설명
자연어 분석 챗	현업 사용자가 질문하면 표, 차트, SQL, 해석 제공

도메인 사전 관리자	현장 용어, 지표, 컬럼 의미 관리
답변 양식 MCP (도메인 적용 인사이트)	우리 도메인에 맞는 인사이트를 제공 가능하며, 실무자에게 정말 필요한 영역을 커스터 마이징해서 그때그때 필요사항을 끌어올 수 있는 재사용성 가능한 도구
DB 스캐닝 콘솔	테이블/컬럼/값 프로파일링 결과 확인
질문 리스트 콘솔	LLM이 생성한 확인 질문을 담당자가 승인/수정
지표 정의 관리	매출, 전환율, 리텐션 등 공식 계산식 관리
부서별 분석 공간	마케팅, 세일즈, 재무, CX 별 접근 가능한 데이터 분리
SQL 검증 엔진	생성 SQL 의 권한, 비용, 의미 일치 여부 검증
대시보드 생성	자연어 질의 결과를 반복 가능한 리포트로 저장
피드백 루프	틀린 답변을 수정해 verified query 와 도메인 사전에 반영

1-4. 타사 서비스 비교

아래 내용으로 **1-4. 타사 서비스 비교** 부분을 교체하면 됩니다.
워드문서에서는 이 표 하나가 핵심입니다.

1-4. 타사 서비스 비교

비교 기준

기호	의미
O	공식 기능 또는 핵심 기능으로 제공
△	일부 가능하지만 수동 설정, 특정 플랫폼 종속, 또는 제한적 지원
X	해당 서비스의 핵심 기능으로 보기 어려움

경쟁 서비스 기능 비교 매트릭스

비교 항목	Snowflake Cortex Analyst	BigQuery Conversational Analytics	Databricks Genie	Vanna AI	우리 서비스
자연어 기반 데이터 질의 / SQL 생성	O	O	O	O	O
Semantic layer / glossary / metadata 설정	O	O	O	△	O
Verified query / sample query 기반 정확도 보정	O	O	△	△	O

DB 스키마 자동 분석	△	△	△	△	O
컬럼별 distinct / top N 값 자동 수집	△	△	X	X	O
컬럼 값 의미를 값 사전으로 자동 문서화	X	△	X	X	O
LLM이 현장 담당자에게 물어볼 질문 리스트 자동 생성	X	X	X	X	O
Human-in-the-loop 도메인 검수 흐름	△	△	△	△	O
VDB 기반 고객사 도메인 메모리 구축	△	△	△	△	O
여러 DB / 웨어하우스에 독립적으로 적용	X	X	X	△	O
부서별 권한 / 가드레일 적용	O	△	O	O	O
고객사 전용 분석 플랫폼 end-to-end 구축	△	△	△	△	O

- **Snowflake Cortex Analyst**는 **Snowflake** 구조화 데이터를 대상으로 자연어 질의, **REST API, semantic model/view, RBAC** 기반 거버넌스를 제공한다.
- 특히 **semantic model**이 비즈니스 용어와 **DB** 정의 사이의 간극을 줄이는 역할을 한다고 설명한다. **BigQuery Conversational Analytics**는 **data agent, custom metadata, instruction, verified query, glossary**를 제공해 **BigQuery** 데이터에 대한 자연어 분석을 지원한다.

- **Databricks Genie**는 **domain expert**가 **datasets, sample queries, text guidelines**를 설정해 조직 용어에 맞는 분석 공간을 구성하는 방식이다.
- **Vanna AI**는 **LLM**을 **DB**에 연결하고 **Tool Memory**와 **permission flow**를 통해 **SQL** 질의와 사용자별 접근 제어를 지원한다.

표에서 보이는 핵심 차이

구분	기존 서비스들이 강한 부분	기존 서비스들의 공통 한계	우리가 공략하는 지점
자연어 분석	자연어 질문을 SQL 이나 분석 결과로 변환	특정 데이터 플랫폼 내부 기능에 가까움	여러 DB 위에 올라가는 커스텀 분석 플랫폼
Semantic 설정	glossary, metadata, sample query, semantic model 제공	사람이 직접 설정해야 하는 비중이 큼	LLM 이 DB 를 먼저 스캔하고 설정 후보를 자동 생성
정확도 보정	verified query, sample query, instruction 사용	이미 아는 질문을 보정하는 데 강함	모르는 현장 용어를 질문 리스트로 역생성
도메인 맥락 구축	일부 metadata / instruction 관리 가능	컬럼 값 의미, 현장 용어, 지표 정의를 end-to-end 로 수집하지 않음	distinct 값, 지표, 조인 규칙, 현장 용어를 VDB 에 자동 문서화

	자연어 분석 공간 제공	guidelines 를 직접 구성해야 함	설정 후보와 질문을 뽑아줌
Vanna AI	DB 연결, SQL 질의, Tool Memory, permission flow	agent framework 성격이 강하고, 고객사별 값 사전·현장 용어·지표 정의를 end-to-end 로 구축하는 데는 제한적	단순 agent 가 아니라 고객사 전용 도메인 메모리와 분석 플랫폼을 생성

우리 서비스의 타겟 포지션

기존 서비스들은 각각 일부 요소를 만족한다.

Snowflake / BigQuery / Databricks

→ 자연어 분석과 **semantic** 설정은 강함

→ 하지만 각자 플랫폼 중심

Vanna AI

→ 개발자 친화적 **agent framework**는 강함

→ 하지만 고객사 도메인 구축 자동화는 약함

우리 서비스

→ **DB 스캔 + 현장 질문 생성 + 값 사전 구축 + VDB 문서화 + 분석 플랫폼 생성까지
end-to-end** 제공

우리 서비스의 차별화 포인트

1. DB를 연결하면 기업별 데이터 해석 지도를 자동 생성한다

단순히 테이블명과 컬럼명을 읽는 것이 아니라, **LLM**이 **DB** 구조와 컬럼 값을 분석한다.

예를 들어 다음을 자동으로 파악한다.

분석 대상	예시
테이블 역할	payments 는 결제 fact table 후보
주요 날짜 기준	paid_at, created_at, approved_at 중 어떤 것이 지표 기준일인지 확인 필요
카테고리 컬럼	status, type, channel, grade
distinct 값	A, D, S, PAID, CANCELLED
조인 후보	user_id, order_id, payment_id
지표 후보	매출, 환불액, 결제건수, 전환율

2. **LLM**이 “물어봐야 할 질문”을 역으로 생성한다

기존 방식은 사람이 테이블과 지표를 처음부터 설명해야 한다.
우리 서비스는 반대로 **LLM**이 **DB**를 보고 모르는 부분을 질문으로 만든다.

예시:

DB 에서 발견한 모호한 부분	LLM 이 생성하는 확인 질문
-------------------------	-------------------------

users.created_at, users.first_paid_at 둘 다 존재	“신규 고객은 가입일 기준인가요, 첫 결제일 기준인가요?”
orders.amount, payments.amount, settlements.amount 모두 존재	“매출은 주문금액, 결제금액, 정산금액 중 무엇을 기준으로 하나요?”
status = A, D, S 존재	“ A, D, S 는 각각 현업에서 어떤 고객 상태를 의미하나요?”
utm_campaign, campaign_id 모두 존재	“캠페인 성과는 UTM 기준인가요, 내부 campaign_id 기준인가요?”

이 부분이 발표에서 가장 강한 차별점입니다.

3. distinct 값과 현장 용어를 VDB에 자동 문서화한다

카테고리성 컬럼은 **distinct, top N, count** 등을 통해 값 후보를 수집한다.

예시:

테이블	컬럼	값	현장 의미
users	status	A	활성 고객
users	status	D	탈퇴 고객
users	status	S	휴면 고객
payments	status	PAID	결제 완료

payments	status	CANCELLED	결제 취소
-----------------	---------------	------------------	-------

이 값 사전은 **VDB**에 임베딩된다.

이후 사용자가 “휴면 고객 중 지난달 다시 결제한 사람”이라고 물으면, **LLM**은 휴면 고객 = **users.status = 'S'** 라는 맥락을 검색해서 **SQL**에 반영한다.

4. 파인튜닝 없이 고객사 맥락을 아는 분석 **LLM**으로 동작한다

우리 서비스는 고객사별 모델을 새로 학습시키지 않는다.

대신 다음 구조로 작동한다.

DB 스캔

→ 컬럼 값 수집

→ 현장 질문 생성

→ 담당자 검수

→ 지표 / 용어 / 값 사전 문서화

→ **VDB** 임베딩

→ 질의 시점에 관련 컨텍스트 검색

→ 고객사 맥락이 반영된 **SQL** / 분석 결과 생성

즉, 전통적인 학습이 아니라 도메인 컨텍스트 구축 + **RAG + semantic layer** 방식으로 고객사 맞춤화를 구현한다.

우리 서비스의 차별화 포인트

1. **DB**를 연결하면 끝나는 것이 아니라, **LLM**이 스키마와 컬럼 값을 스캔해 기업별 데이터 해석 지도를 자동 생성한다.
2. **LLM**이 모르는 현장 용어는 추측하지 않고, 담당자에게 물어봐야 할 질문 리스트를 역으로 생성해 **human-in-the-loop** 방식으로 도메인 지식을 수집한다.

3. 컬럼별 **distinct** 값, 지표 정의, 조인 패턴, 현장 용어, **verified query**를 **VDB**에 자동 문서화하여, 별도 파인튜닝 없이도 고객사 맥락을 아는 분석 **LLM**을 만든다.
-

2. 사용자 시나리오

2-1. 대표 페르소나

이름 / 직업 / 상황

이서준 / **AI** 솔루션 엔지니어 / 고객사 맞춤형 데이터 분석 플랫폼 구축 담당자

서준은 고객사의 **Snowflake, BigQuery, PostgreSQL** 또는 사내 **DB**를 연결해, 임직원이 자연어로 데이터를 분석할 수 있는 커스텀 플랫폼을 구축해야 한다.

고객사는 다음을 요구한다.

- “우리 회사 용어를 알아듣는 분석 챗봇”
- “마케팅팀, 재무팀, **CX**팀별로 다른 데이터 접근 권한”
- “매출, 전환율, 활성 고객 같은 지표를 우리 기준으로 계산”
- “기존 **BI** 대시보드와 일관된 결과”
- “초기 구축 기간을 짧게”

서준은 단순 **Text-to-SQL**로는 부족하다고 판단한다.

이유는 고객사마다 현장 용어와 **DB** 구조가 다르고, 컬럼 값의 의미가 문서화되어 있지 않기 때문이다.

목표

- 고객사 **DB**를 빠르게 스캔한다.
 - 테이블/컬럼/값의 의미를 자동 추론한다.
 - 담당자에게 확인해야 할 질문 리스트를 자동 생성한다.
 - 승인된 현장 용어와 지표 정의를 **VDB**에 문서화한다.
 - 고객사 전용 자연어 데이터 분석 플랫폼을 구축한다.
 - 별도 모델 파인튜닝 없이 도메인 맥락을 반영한다.
-

제약 조건

- 고객사 데이터는 외부 학습에 사용되면 안 된다.
- **PII** 값은 **VDB**에 그대로 저장하면 안 된다.

- 현장 용어는 문서화되어 있지 않거나 담당자 머릿속에만 있다.
 - 테이블 수가 많아 사람이 직접 전부 설명하기 어렵다.
 - 부서별 권한과 지표 기준이 다르다.
 - 잘못된 SQL 결과가 경영 의사결정에 영향을 줄 수 있다.
-

2-2. 시나리오 — Before → During → After

Before

고객사는 “자연어로 데이터를 물어보는 분석 플랫폼”을 원한다.

하지만 초기 점검 결과 다음 문제가 발견된다.

- 테이블이 300개 이상임
 - `status`, `type`, `code` 같은 추상 컬럼이 많음
 - “매출”이라는 용어가 부서마다 다르게 쓰임
 - BI 대시보드 SQL은 있지만 문서화가 부족함
 - 현업은 SQL을 모르고, 데이터팀은 현업 용어를 일부만 알고 있음
 - 기존 LLM은 `orders.created_at`과 `payments.paid_at`을 혼동함
-

During

서준은 플랫폼을 통해 다음 과정을 진행한다.

1. 고객사 DB read-only 연결
 2. 분석 대상 `schema` 선택
 3. DB 자동 스캐닝 실행
 4. 테이블/컬럼/값 프로파일링 수행
 5. 저카디널리티 컬럼에 대해 `distinct` 값 수집
 6. LLM이 테이블과 컬럼의 의미를 1차 추론
 7. LLM이 담당자에게 물어볼 질문 리스트 생성
 8. 데이터 담당자와 현업 담당자가 질문에 답변
 9. 시스템이 답변을 바탕으로 도메인 사전 생성
 10. 컬럼 값 사전, 지표 정의, 조인 패턴을 VDB에 임베딩
 11. 부서별 분석 공간과 권한 정책 생성
 12. 자연어 질의 테스트
 13. 틀린 결과는 `verified query`로 보정
 14. 고객사 전용 분석 플랫폼 오픈
-

After

현업 사용자가 질문한다.

“지난달 신규 고객 순매출을 캠페인별로 보여줘.”

플랫폼은 다음 과정을 수행한다.

1. “신규 고객” 정의 검색
 - `first_paid_at` 기준
2. “순매출” 정의 검색
 - 결제금액 - 환불금액 - 쿠폰 할인
3. “캠페인” 정의 검색
 - UTM 기준 우선, 없으면 내부 `campaign_id` 사용
4. 사용자 부서 권한 확인
 - 마케팅팀은 캠페인 성과와 집계 매출만 조회 가능
5. SQL 생성
6. SQL 의미를 다시 자연어로 설명
7. 정책 위반 및 비용 확인
8. 결과 제공

결과적으로 사용자는 SQL을 몰라도 고객사 기준에 맞는 분석 결과를 얻는다.

3. 서비스 흐름 — Input → Process → Output

3-1. Input

사용자 입력 데이터

입력	설명
자연어 질문	“지난달 신규 고객 매출 알려줘”
사용자 정보	user_id, role, department, permission group

분석 목적	매출 분석, 마케팅 분석, 고객 분석, 운영 분석
출력 형식	표, 차트, SQL, 요약 리포트
실행 모드	미리보기, SQL 생성, 실제 실행, 승인 필요

초기 세팅 입력 데이터

입력	설명
DB 연결 정보	Snowflake, BigQuery, Databricks, PostgreSQL, MySQL 등
schema/table 목록	분석 대상 데이터 범위
information_schema	테이블, 컬럼, 타입, nullable 등
sample data	제한된 샘플 값
distinct values	카테고리성 컬럼의 값 목록
query logs	기존 사용 SQL, 자주 쓰는 조인/필터
BI metadata	Looker, Tableau, Superset, Metabase, dbt 문서
현업 답변	LLM이 생성한 질문에 대한 담당자 답변

권한 정책	부서별 접근 가능 테이블/컬럼/지표
민감정보 정책	PII, PHI, 재무 민감정보 처리 기준

Knowledge Base / VDB 문서

문서	설명
Table Card	테이블 목적, 주요 컬럼, 대표 사용 사례
Column Card	컬럼 의미, 타입, 값 분포, 관련 용어
Value Dictionary	distinct 값과 현장 용어 매핑
Metric Definition	지표 계산식
Business Glossary	현업 용어 정의
Join Recipe	권장 조인 경로
Filter Recipe	기본 필터 조건
Department Policy	부서별 접근 정책
Verified Query	검증된 질문-SQL 쌍

Ambiguity Rule	모호할 때 되물어야 하는 조건
----------------	------------------

3-2. Process

전체 프로세스

1. DB 연결
2. 스키마 스캔
3. 컬럼 값 프로파일링
4. LLM 기반 의미 추론
5. 현장 용어 확인 질문 생성
6. 사람 검수 및 승인
7. 도메인 사전 / 값 사전 / 지표 정의 생성
8. VDB 임베딩
9. 고객사별 분석 에이전트 생성
10. 자연어 질의 처리
11. SQL 생성 및 검증
12. 결과 제공
13. 피드백 반영

1단계. Safe DB Scanner

DB에 read-only로 접근해 안전한 범위에서 metadata와 sample을 수집한다.

핵심 원칙:

- 운영 DB 부하 최소화
- 민감정보 원문 저장 금지
- PII 의심 컬럼은 값 수집 제외
- 고카디널리티 컬럼은 전체 distinct 수집 금지
- 쿼리 비용 제한 적용

2단계. Column Value Profiler

컬럼별로 분석 방식을 다르게 적용한다.

컬럼 유형	처리 방식
저카디널리티	DISTINCT 값, 빈도, 비율 수집
중카디널리티	Top N 값, sample 값, 패턴 수집
고카디널리티	cardinality, null ratio, format pattern만 수집
날짜 컬럼	min/max, 월별 분포, timezone 후보
금액 컬럼	min/max, 평균, 음수 여부, 통화 후보
ID 컬럼	unique ratio, join key 후보
PII 의심 컬럼	원문 수집 금지, 마스킹 정책만 기록

3단계. LLM Semantic Hypothesis

수집된 metadata를 바탕으로 LLM이 1차 가설을 만든다.

예시:

```
{
  "table": "payments",
  "hypothesis": "결제 트랜잭션 테이블",
  "key_columns": ["payment_id", "user_id", "paid_at", "amount", "status"],
  "possible_metrics": ["매출", "결제 건수", "환불 제외 매출"],
  "uncertainties": [
    "amount가 총 결제금액인지 할인 후 결제금액인지 확인 필요",
    "status = 'PAID'와 'CONFIRMED'의 차이 확인 필요",
    "paid_at과 approved_at 중 공식 매출 기준일 확인 필요"
  ]
}
```

4단계. Reverse Question Generator

LLM이 불확실한 부분을 질문 리스트로 변환한다.

예시:

`payments.amount`는 현업에서 '매출'로 사용되는 값인가요?
아니면 할인/쿠폰/포인트 차감 전 금액인가요?

`payments.status = 'PAID'`와 `'CONFIRMED'` 중
매출 집계에 포함해야 하는 상태는 무엇인가요?

월별 매출 집계 시 `paid_at`, `approved_at`, `created_at` 중
어떤 날짜를 기준으로 하나요?

이 기능은 고객사 온보딩에서 매우 중요하다.

사람이 모든 테이블을 설명하는 것이 아니라, 시스템이 “ 물어봐야 할 질문 ”을 먼저
뽑아준다.

5단계. Human Confirmation

담당자는 질문에 답변하거나, LLM의 추론을 승인/수정한다.

예시:

질문	담당자 답변
신규 고객 기준은?	최초 결제일 기준
매출 기준은?	환불 제외 순매출
캠페인 기준은?	UTM campaign 우선
활성 고객 기준은?	<code>status = A AND deleted_at IS NULL</code>

월별 기준일은?	paid_at 기준
----------	------------

6단계. Semantic Pack Builder

승인된 답변을 기반으로 고객사별 semantic pack을 만든다.

semantic_pack: revenue_analysis

business_terms:

new_customer:

ko: 신규 고객

definition: 최초 결제일이 분석 기간에 속한 고객

sql_condition: users.first_paid_at BETWEEN {start_date} AND {end_date}

metrics:

net_revenue:

ko: 순매출

formula: payments.amount - refunds.amount - coupon_discount.amount

date_basis: payments.paid_at

value_dictionary:

users.status:

A: 활성 고객

S: 휴면 고객

D: 탈퇴 고객

guardrails:

allowed_roles:

- finance

- executive

blocked_columns:

- users.email

- users.phone

7단계. VDB Embedding

semantic pack을 문서 단위로 쪼개 VDB에 저장한다.

검색 예시:

사용자 질문:

“휴면 고객 중 지난달 다시 결제한 사람 수 알려줘.”

검색되는 컨텍스트:

- `users.status = 'S'`는 휴면 고객
 - 재결제는 `payments.paid_at` 기준
 - 고객 수는 `COUNT(DISTINCT users.user_id)`
 - 마케팅팀은 개인 식별정보 조회 불가
 - 기간은 지난달로 해석 가능
-

8단계. Domain-Aware Query Agent

질의 시점에는 다음 순서로 작동한다.

사용자 질문



의도 분석



관련 semantic pack 검색



관련 table/column/value/metric card 검색



모호성 확인



필요 시 되묻기



SQL 생성



정책 검증



SQL 의미 역검증



실행



결과 해석 및 시각화

3-3. Output

최종 사용자에게 보이는 결과

사용자 질문:

“지난달 신규 고객 순매출을 캠페인별로 보여줘.”

응답:

2026년 4월 기준 신규 고객 순매출을 캠페인별로 집계했습니다.

적용 기준:

- 신규 고객: 최초 결제일이 2026년 4월에 속한 고객
- 순매출: 결제금액 - 환불금액 - 쿠폰 할인액
- 캠페인: UTM campaign 기준
- 기간 기준: paid_at
- 권한 정책: marketing_analyst 기준, 개인 식별정보 제외

캠페인	신규 고객 수	순매출
spring_sale	1,240	58,200,000
referral	820	31,600,000
brand_search	610	24,700,000

추가 제공:

- 생성 SQL
- 사용된 지표 정의
- 사용된 컬럼
- 적용된 권한 정책
- 신뢰도
- 주의사항
- verified query로 저장하기
- 대시보드로 저장하기

관리자에게 보이는 결과

관리자 콘솔에는 다음이 표시된다.

화면	내용
----	----

DB Map	테이블 관계, 주요 fact/dimension 후보
Domain Dictionary	현장 용어와 SQL 조건 매핑
Value Dictionary	컬럼 값과 의미 매핑
Question Queue	담당자에게 확인해야 할 질문 목록
Semantic Pack	부서/도메인별 분석 패키지
Query Audit	누가 어떤 질문을 했고 어떤 SQL이 실행됐는지
Failure Review	실패한 질문, 수정된 SQL, 개선 필요 컨텍스트
Coverage Report	문서화된 테이블/컬럼/지표 비율

3-4. 품질 기준 KPI

KPI	정의	MVP 목표
DB 스캔 커버리지	선택된 schema 중 프로파일링 완료된 테이블 비율	90%+
컬럼 의미 추론 승인율	LLM 추론 중 사람이 승인한 비율	60%+

현장 질문 유효율	생성 질문 중 담당자가 “필요한 질문”이라고 판단한 비율	70%+
값 사전 커버리지	카테고리성 컬럼 중 값 사전이 생성된 비율	80%+
지표 정의 커버리지	주요 KPI 중 공식 정의가 등록된 비율	70%+
VDB 검색 적중률	사용자 질문에 필요한 context 가 검색되는 비율	85%+
SQL 의미 일치율	생성 SQL이 현장 정의와 일치하는 비율	75%+
모호 질의 되묻기율	조건 누락 시 임의 생성 대신 되묻는 비율	80%+
권한 위반 차단율	금지 컬럼/테이블 접근 차단 비율	95%+
분석 플랫폼 온보딩 시간	DB 연결부터 첫 유효 질의까지 걸리는 시간	1~3일 내

4. 비즈니스 모델

4-1. 수익 구조

이 서비스는 단순 SaaS보다 커스텀 분석 플랫폼 구축형 **B2B** 모델이 더 적합하다.

모델	설명
----	----

초기 구축비	고객사 DB 스캔, semantic pack 구성, 현장 용어 정리, 권한 정책 설계
월 구독료	분석 플랫폼 사용, VDB 관리, 쿼리 검증, 대시보드, 로그 관리
사용량 과금	자연어 질의 수, SQL 검증 수, VDB 검색량, LLM 호출량
부서별 seat 과금	마케팅, 재무, CX 등 사용자 수 기반
엔터프라이즈 과금	VPC 배포, SSO , 감사 로그, 전용 connector , 보안 심사 대응
Managed semantic layer	고객사 지표/용어/값 사전을 지속 관리해주는 운영 서비스

추천 패키지

플랜	대상	제공 가치
PoC Pack	스타트업/중소 기업	1개 DB 연결, 주요 테이블 30개 스캔, 기본 분석 챗
Team Analytics Pack	부서 단위	마케팅/재무/ CX 등 특정 도메인 분석 플랫폼 구축
Enterprise Data Copilot	전사 도입	부서별 권한, semantic pack , 감사 로그, VPC 배포

Embedded Analytics Builder	B2B SaaS	고객사별 분석 에이전트를 제품 안에 내장
-------------------------------	----------	---------------------------
